UNIVERSIDAD EXTERNADO DE COLOMBIA · BIG DATA 2026-II

Consultoría en Big Data: Procesamiento Distribuido de Reclamaciones Financieras

Análisis de 15 Millones de Quejas con Apache Spark sobre Hadoop YARN y HDFS (2023–2026)

Entidad Contratante: Consumer Financial Protection Bureau (CFPB) – EE. UU.

Integrantes del Equipo: Arnold Santiago Torres Anzola · Nicolas Felipe Figueroa Salgado · Alejandro Esteban Martinez Acosta

Docente: Yessica Liceth Velasquez Castiblanco · **Grupo:** MABD02 (o MABD01)

Entorno: Clúster Físico Sala Deep Learning (1 Master + 2 Workers) · **Sustentación:** Miércoles 18 de Noviembre de 2026

Entrega Técnica y Sustentación Oral · Máximo 3 Diapositivas por Componente

COMPONENTE A: DATOS Y ALMACENAMIENTO (1/3)

Selección Oficial, Poda y Validación del Dataset

Fuente Oficial y Relevancia

• **Entidad:** Consumer Financial Protection Bureau (CFPB) / Data.gov.
• **Dominio:** Protección al consumidor financiero ante abusos en créditos e hipotecas.
• **Actualización:** Diario; se tomaron registros hasta el **5 de noviembre de 2026**.
• **Unicidad:** Dataset único aprobado con trazabilidad oficial.

Poda Metodológica Justificada

• **Volumen Original:** 18,9M filas (~5,8 GB), excedía el límite de 5 GB.
• **Criterio de Poda:** Descarte del histórico antiguo (2011 a 2023-I: 3,9M filas eliminadas).
• **Datos Preservados:** 100% de la tendencia reciente contemporánea (2023-II a nov-2026).
• **Tamaño Final: ~4,6 GB descomprimido / 15.017.091 filas** (Rango 2-5 GB).

Respaldo en Nube y Acceso

• **Restricción:** Bloqueo de puertos USB por ciberseguridad en la sala.
• **Respaldo:** GitHub Releases v1.0.0 con enlace directo mediante curl.
• **Esquema Oficial:** 15 atributos (Date received, Product, Issue, Company, State, Response, etc.).

COMPONENTE A: DATOS Y ALMACENAMIENTO (2/3)

Estrategia de Ingesta Directa a HDFS sin Copia Local

Desafío de Almacenamiento Local

• **Riesgo:** Las máquinas virtuales del laboratorio tienen espacio de disco reducido.
• **Regla:** Se requiere 3x del dataset (copia local + 2 réplicas HDFS = 14 GB).
• Si se descargaba en el disco local antes de pasarlo a HDFS, el nodo maestro colapsaba por falta de almacenamiento.

Tubería Streaming en Memoria

• **Solución de Ingesta:** Canalización directa desde URL hacia HDFS en memoria estándar: curl -L -s <URL> | funzip | hdfs dfs -put - /caso/complaints_4.5gb.csv
• **Ventaja:** 0 bytes de desperdicio en el almacenamiento del sistema operativo anfitrión.

Configuración de Replicación = 2

• **Tolerancia a Fallos:** Se aplicó factor de replicación explícito:
hdfs dfs -setrep -R 2 /caso/complaints_4.5gb.csv
• **Respaldo de Evidencia:** Captura C2 del portal NameNode (puerto 9870) mostrando Replication = 2.

COMPONENTE A: DATOS Y ALMACENAMIENTO (3/3)

Auditoría Distribuida de Bloques y DataNodes (Capturas C1, C2, C3)

Estado del Clúster (Captura C1)

• **Portal NameNode (9870):** Pestaña *Datanodes* confirma 2 nodos trabajadores activos.
• **Balanceo:** Ambos DataNodes en servicio, con almacenamiento homogéneo y capacidad suficiente para alojar los 15M de registros.

Auditoría con hdfs fsck (Captura C3)

• **Comando:** hdfs fsck /caso/... -files -blocks -locations
• **Status:** HEALTHY (sin bloques corruptos ni perdidos).
• **Average Block Replication:** Exactamente **2,0**.
• **Ubicación de bloques:** Verificación de réplicas cruzadas entre DataNode 1 y DataNode 2.

Métricas Clave Observadas

• **Total Size:** ~4.939.210.752 bytes (~4,6 GB).
• **Tamaño por Bloque HDFS:** 128 MB estándar.
• **Total de Bloques Distribuidos:** ~37 bloques por réplica (74 bloques totales en el clúster).

COMPONENTE B: PROCESAMIENTO (1/3)

Configuración Optimizada de SparkSession sobre YARN (Capturas C4 y C5)

Parámetros de Ejecución Justificados

• **master('yarn'):** Orquestación distribuida formal en lugar de modo local.
• **executor.memory = 4g:** 4 GB de RAM por worker para evitar OOM y derrames a disco.
• **executor.cores = 2:** Óptimo paralelismo sin sobrecargar la recolección de basura (GC).
• **executor.instances = 2:** 2 ejecutores en los 2 nodos físicos (4 tareas concurrentes).

Adaptive Query Execution (AQE)

• **spark.sql.adaptive.enabled = true:** Optimización dinámica de planes en tiempo de ejecución.
• **spark.sql.shuffle.partitions = 200:** Particionamiento balanceado para operaciones de shuffle masivo.
• **driver.memory = 2g:** Memoria suficiente para coordinar y recibir resultados agregados.

Trazabilidad YARN (Captura C4)

• **application_id de Referencia:** Capturado en la primera corrida exitosa del 9 de noviembre.
• **Portal ResourceManager (8088):** Estado RUNNING/FINISHED con usuario hadoop y cola default.

COMPONENTE B: PROCESAMIENTO (2/3)

Análisis Exploratorio de Datos (EDA) sobre 15 Millones de Registros

Ingesta Acelerada con StructType

• **Esquema Explícito:** Se definió StructType estricto para las 15 columnas.
• **Ventaja Técnica:** Evitó el doble escaneo completo de 4,6 GB que exige inferSchema, reduciendo el tiempo de carga a solo segundos.

Distribución Temporal y Conteo

• **Conteo Total Verificado: 15.017.091 filas** (formateado con fmt_co).
• **Evolución Anual:**
- 2023-II: 586.449 (3,9%)
- 2024: 2.734.268 (18,2%)
- 2025: 5.442.933 (36,2%)
- 2026: 6.253.441 (41,6%) -> Crecimiento crítico del volumen de quejas.

Calidad de Datos y Canales

• **Nulos Críticos:** Columnas principales (producto, empresa, fechas) con 0% de nulos.
• Subproducto y subproblema con nulos parciales esperados.
• **Canal Dominante:** Web concentra >85% de las radicaciones ciudadanas.

COMPONENTE B: PROCESAMIENTO (3/3)

Transformaciones Complejas y Plan Físico AQE (Capturas C6 y C7)

Transformación 1: Latencia y Eficiencia

• **Latencia:** datediff(fecha_envio, fecha_recibida).
• **Agregación Multivariada:** Por producto financiero: volumen, días promedio de remisión, tasa de respuesta a tiempo y tasa de alivio monetario al consumidor.

Transformación 2: Join Regional

• **Cadena Perezosa:** 5 transformaciones encadenadas (filtro, índice de severidad, agrupación).
• **Broadcast Hash Join:** Cruce con tabla pequeña de macro-regiones de EE.UU. difundida a todos los workers sin shuffle de red.

Contraste de Planes AQE

• **Plan Inicial (Captura C6):** Salida .explain() muestra **AdaptiveSparkPlan isFinalPlan=false**.
• **Plan Final (Captura C7):** Spark UI SQL Details muestra **isFinalPlan=true** tras optimizar particiones en runtime.

COMPONENTE C: DESEMPEÑO Y RESULTADOS (1/3)

Análisis de Spark UI y Monitoreo de Stages Críticos (Capturas C8 y C9)

Stage Relevante 1 (Captura C8)

• **Criterio de Relevancia:** Mayor volumen de Shuffle Read / Shuffle Write del job.
• **Causa:** Redistribución masiva de 15M de filas para el groupBy(producto).
• **Métricas:** Balanceo equitativo entre tareas, duración mediana controlada y **cero derrames a disco (Spill disk: ninguno)**.

Stage Relevante 2 (Captura C9)

• **Criterio de Relevancia:** Combinación y ordenamiento global con Join regional.
• **Optimización AQE:** Reducción dinámica de particiones de shuffle ociosas (coalescing), evitando overhead en el cluster.
• **Eficiencia:** Tareas ejecutadas en paralelo sobre los 4 cores disponibles.

Diagnóstico de Cuellos de Botella

• La serialización y el tráfico de red en shuffle fueron el componente de mayor peso.
• La configuración de 4 GB de RAM por worker fue clave para contener los buffers en memoria.

COMPONENTE C: DESEMPEÑO Y RESULTADOS (2/3)

Persistencia, Patrón de Visualización y Hallazgos (Captura C10)

Política de Persistencia (Captura C10)

• **Nivel:** MEMORY_AND_DISK sobre el DataFrame base reutilizado.
• **Justificación:** Evita recalcular transformaciones previas para las visualizaciones y el modelo MLlib.
• **Liberación:** Uso estricto de .unpersist() al concluir.

Patrón Arquitectural de Visualización

• **Patrón:** Spark (distribuido) -> .toPandas() (solo tras agregar) -> Matplotlib.
• **Accesibilidad:** Paleta Okabe-Ito (lineamientos Visualización I), sin bordes innecesarios.
• **Formato Colombiano:** Uso estricto de fmt_co() (punto para miles, coma para decimales).

Hallazgos Clave para el Cliente

• Reportes crediticios concentran el mayor volumen pero con resolución automatizada.
• Hipotecas y cobranza presentan mayor severidad y tasa de compensación monetaria.
• Macro-región Sur y Oeste concentran más del 60% de los reclamos del país.

COMPONENTE C: DESEMPEÑO Y RESULTADOS (3/3)

Recomendación Cloud vs. On-Premise y Bonificación MLlib (Captura C11)

Recomendación Cloud vs. On-Premise

• **Propuesta para CFPB:** Arquitectura híbrida.
• **Spark On-Premise:** Ideal para pipelines batch pesados, depuración histórica y privacidad de datos sensibles (15M filas procesadas en 48 s).
• **BigQuery Serverless:** Ideal para tableros interactivos y auditoría rápida (65,8 MB escaneados en 0,8 s en práctica institucional), sin costos fijos de administración.

Bonificación Spark MLlib (+0,5 Puntos)

• **Pipeline:** StringIndexer -> VectorAssembler -> LogisticRegression distribuida.
• **Objetivo:** Clasificación binaria para predecir si una queja tendrá respuesta a tiempo.
• **Evidencia (Captura C11): ROC-AUC >= 0,78 y Exactitud global** documentadas en celda.